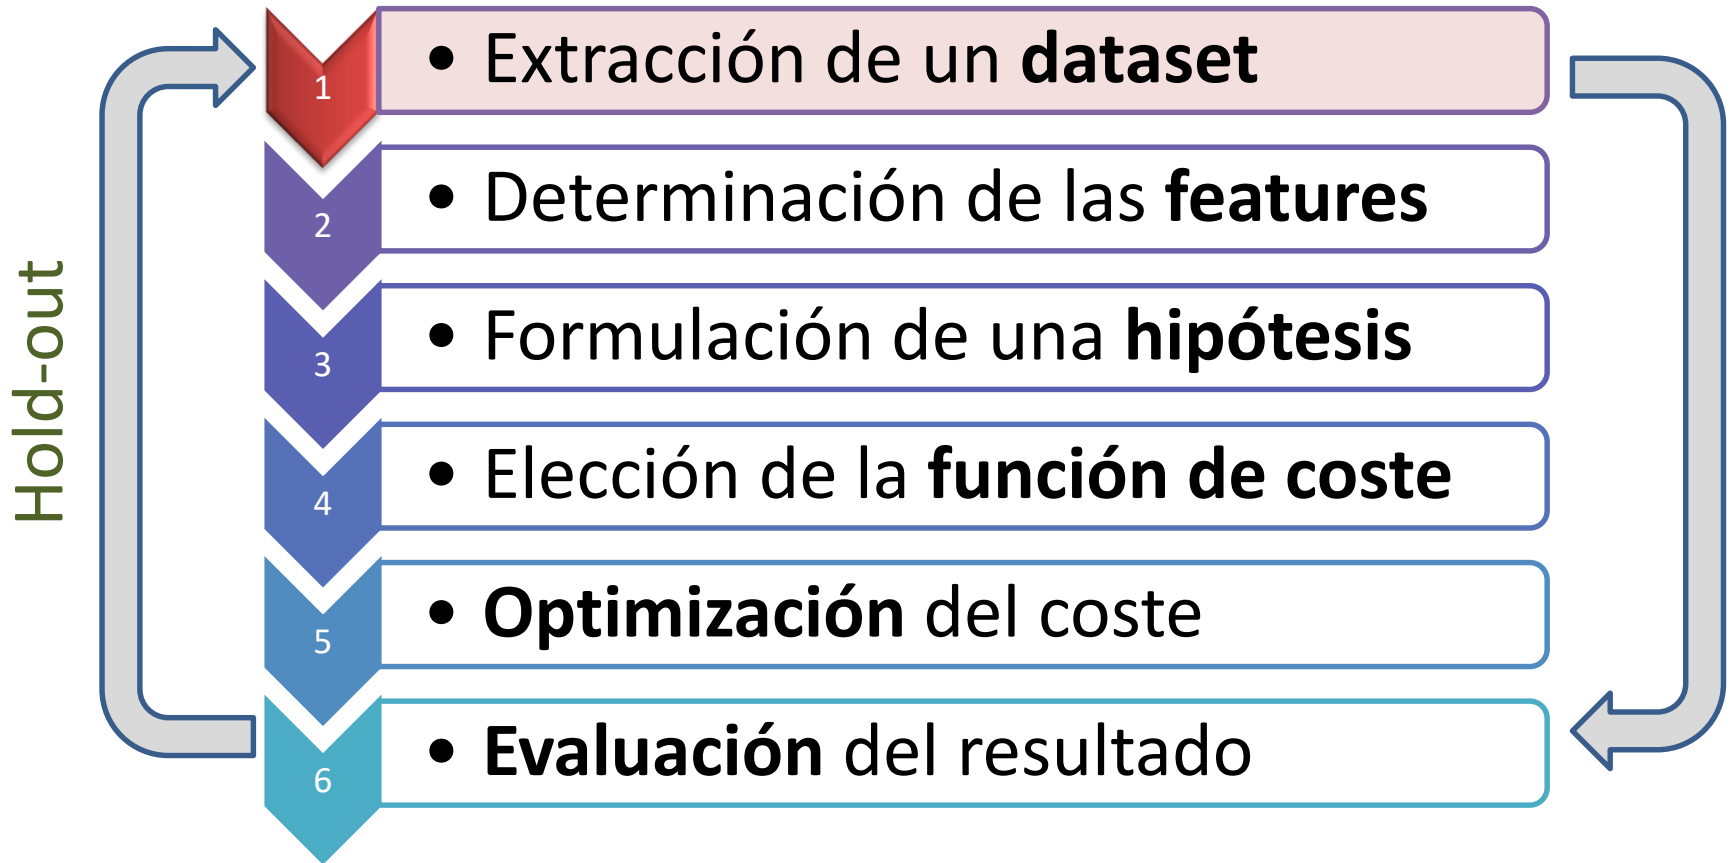



# Pasos del *machine learning*



# Hold-out

## 1. Extracción de una muestra

Población  $\mathcal{P}$



Muestra  $\mathcal{M}$   
(dataset)



Hold-out  
(reserva)


# Hold-out

## 1. Extracción de una muestra

Muestra  $\mathcal{M}$   
(dataset)




Hold-out  
(reserva)



Evaluación de  
resultados

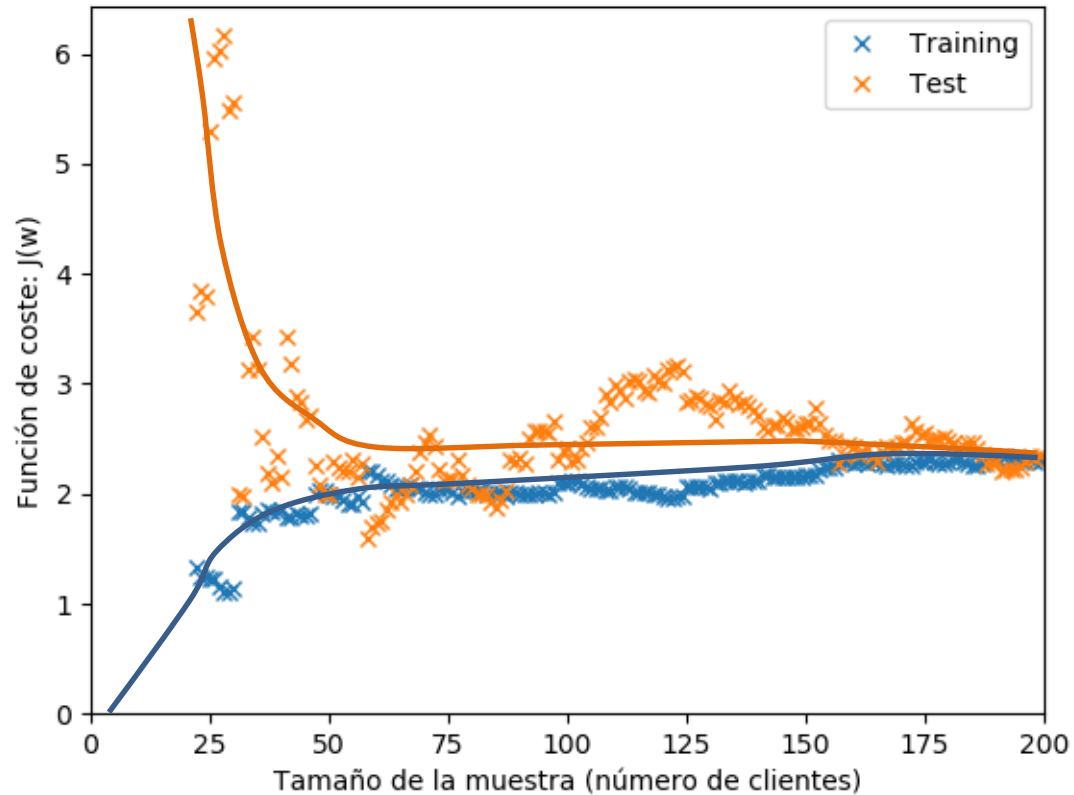
# Hold-out

## 6. Evaluación del resultado



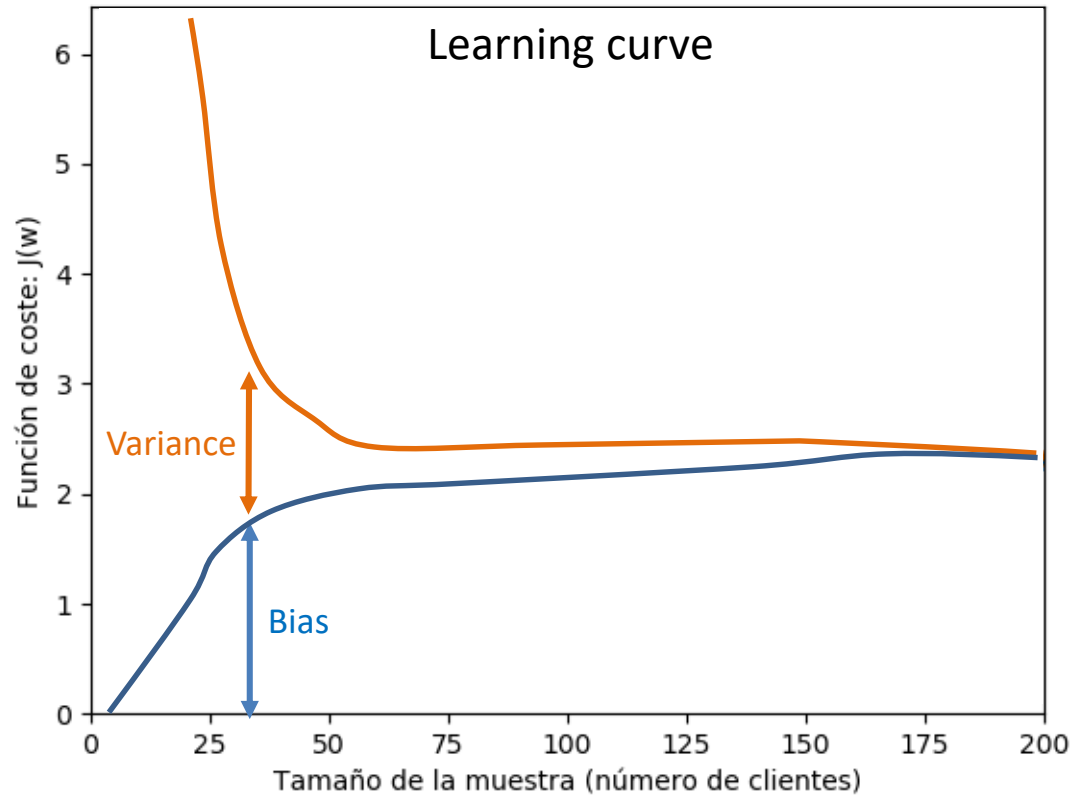
# Hold-out

## 6. Evaluación del resultado



# Hold-out

## 6. Evaluación del resultado

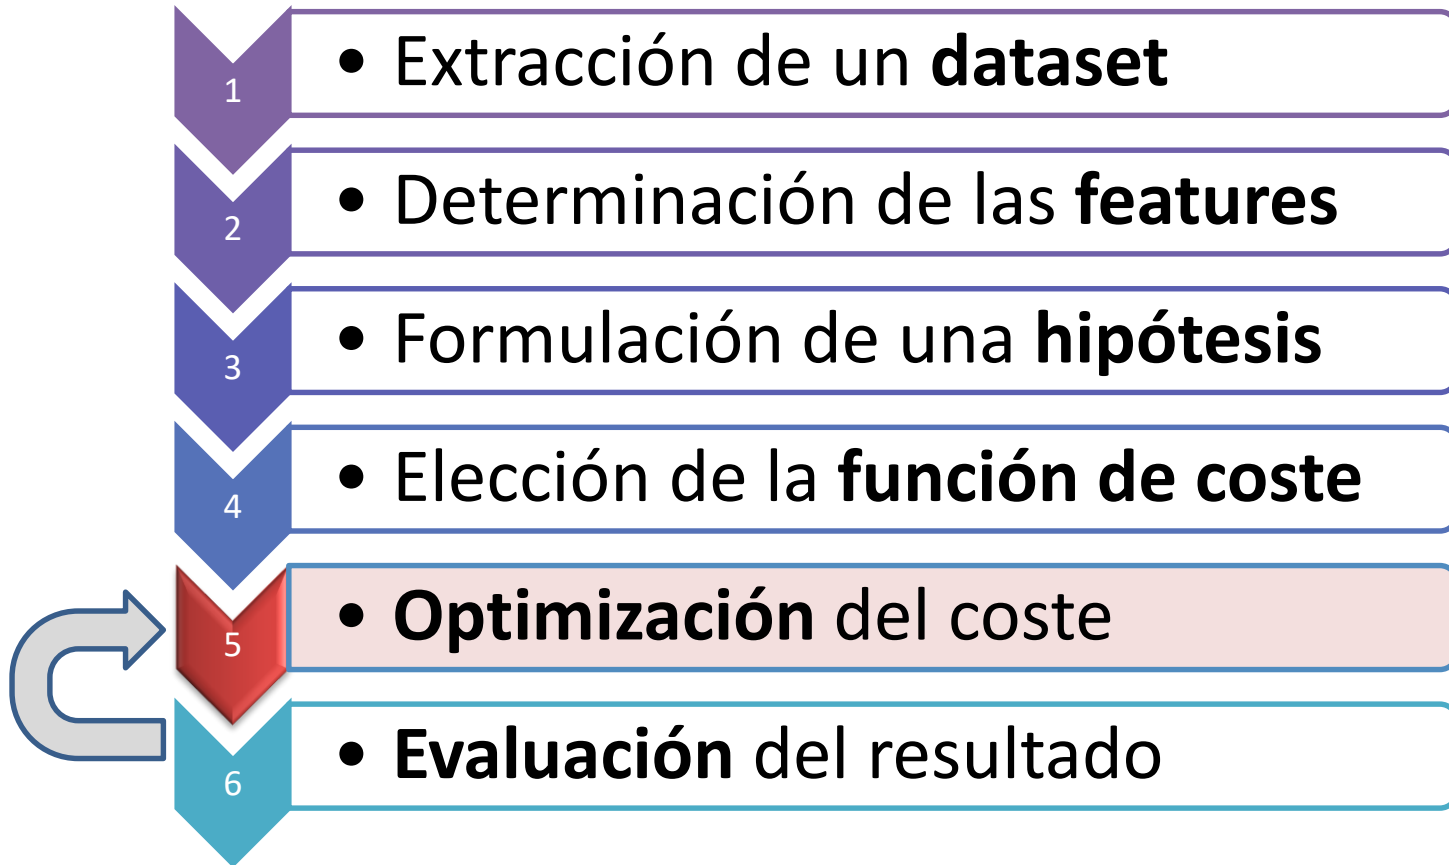


# Regresión univariable

- Muestreo
  - Hold-out
  - Cros-validación
- Hipótesis
  - Regresión lineal (sin *offset*)
  - Regresión lineal
  - Regresión polinómica
- Función de coste
  - Cuadrática
  - Regularización (regresión de arista)
- **Optimización**
  - Ecuación normal
  - **Gradiente descendente**
- Evaluación
  - Bootstrap

# Pasos del *machine learning*

Gradient Descent





# Gradient Descent (GD)

## 5. Optimización del coste

- Problemas de la optimización por Normal Equation
  - El tiempo de cálculo crece con el número de features
  - No es aplicable a todas las funciones de coste
    - A veces no hay solución analítica a la ecuación:

$$\frac{d}{dw} J(h_w(x), y) = 0$$

# Gradient Descent (GD)

## 5. Optimización del coste

- Alternativa: Gradient Descent (GD)


$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \frac{d}{dw} J(h_w(x), y)$$

$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \frac{d}{dw} J(w)$$

$\alpha$ : learning rate

# Gradient Descent (GD)

## 5. Optimización del coste



$\alpha = 2 \cdot 10^{-4}$ : (learning rate) pequeño

# Gradient Descent (GD)

## 5. Optimización del coste

$$\frac{d}{dw}J(w) = \frac{d}{dw} \frac{1}{n} \sum_{i=1}^n (wx^{(i)} - y^{(i)})^2$$

$$\frac{d}{dw}J(w) = \frac{1}{n} \sum_{i=1}^n \frac{d}{dw} (wx^{(i)} - y^{(i)})^2$$

$$\frac{d}{dw}J(w) = \frac{1}{n} \sum_{i=1}^n 2(wx^{(i)} - y^{(i)})x^{(i)}$$

$$\frac{d^2}{dw^2}J(w) = \frac{2}{n} \sum_{i=1}^n x^{(i)2}$$

**Positiva**  
(y constante)

# Gradient Descent (GD)

## 5. Optimización del coste

- Repetir hasta convergencia

Es decir, hasta alcanzar un mínimo de  $J(w)$

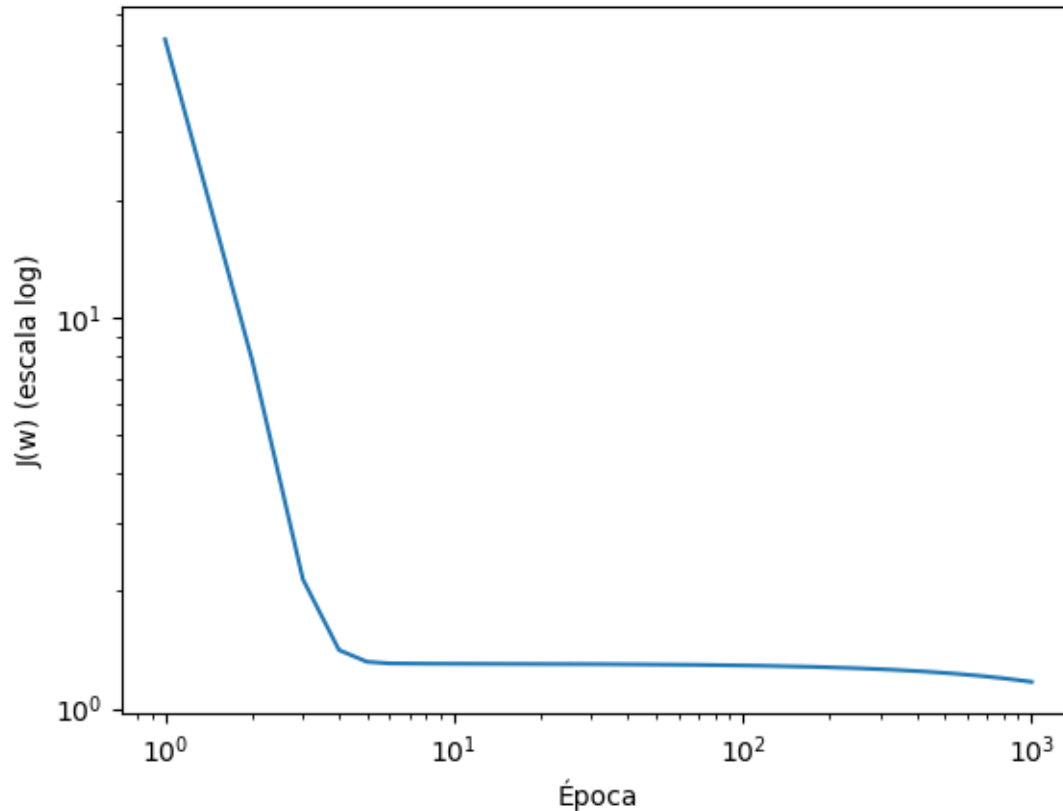
Derivada de la función de  
coste correspondiente  
al  $i$ -ésimo punto

$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \underbrace{\frac{1}{n} \sum_{i=1}^n \overbrace{2(w x^{(i)} - y^{(i)}) x^{(i)}}^{\text{Derivada de la función de coste correspondiente al } i\text{-ésimo punto}}}_{\text{Media de la derivada de la función de coste para todos los puntos}}$$

Media de la derivada  
de la función de coste  
para todos los puntos

# Gradient Descent (GD)


## 5. Optimización del coste



$\alpha = 2 \cdot 10^{-4}$ : (learning rate) pequeño

# Gradient Descent (GD)


## 5. Optimización del coste



$\alpha = 5 \cdot 10^{-4}$ : (learning rate) grande

# Gradient Descent (GD)

## 5. Optimización del coste



$\alpha = 5 \cdot 10^{-4}$ :(learning rate) grande



# Stochastic Gradient Descent (SGD)

## 5. Optimización del coste

- Repetir hasta convergencia
  - Ordenar aleatoriamente los pares  $(x^{(i)}, y^{(i)})$
  - Para  $i = 1, 2, \dots, n$  hacer


$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \underbrace{2(w x^{(i)} - y^{(i)}) x^{(i)}}_{\text{Aproximación a la derivada de la función de coste correspondiente a un único punto}} \quad \left. \vphantom{\underbrace{2(w x^{(i)} - y^{(i)}) x^{(i)}}} \right\} \text{Una época}$$

Aproximación a la derivada  
de la función de coste

Correspondiente a  
un único punto


# Stochastic Gradient Descent (SGD)

## 5. Optimización del coste



# Stochastic Gradient Descent (SGD)

## 5. Optimización del coste



# Batch Gradient Descent (BGD)

## 5. Optimización del coste

- Repetir hasta convergencia
  - Ordenar aleatoriamente los pares  $(x^{(i)}, y^{(i)})$
  - Establecer  $m$  tandas de datos de dimensión  $b$
  - Para tanda =  $1, 2, \dots, m$  hacer

$$w^{(t+1)} \leftarrow w^{(t)} - \alpha \underbrace{\frac{1}{b} \sum_{i=1}^b 2(w x^{(i)} - y^{(i)}) x^{(i)}}_{\text{Aproximación a la derivada de la función de coste}}$$


Una época

Aproximación a la derivada  
de la función de coste

Media correspondiente a  
una tanda de puntos


# Batch Gradient Descent (SGD)

## 5. Optimización del coste



# Batch Gradient Descent (SGD)

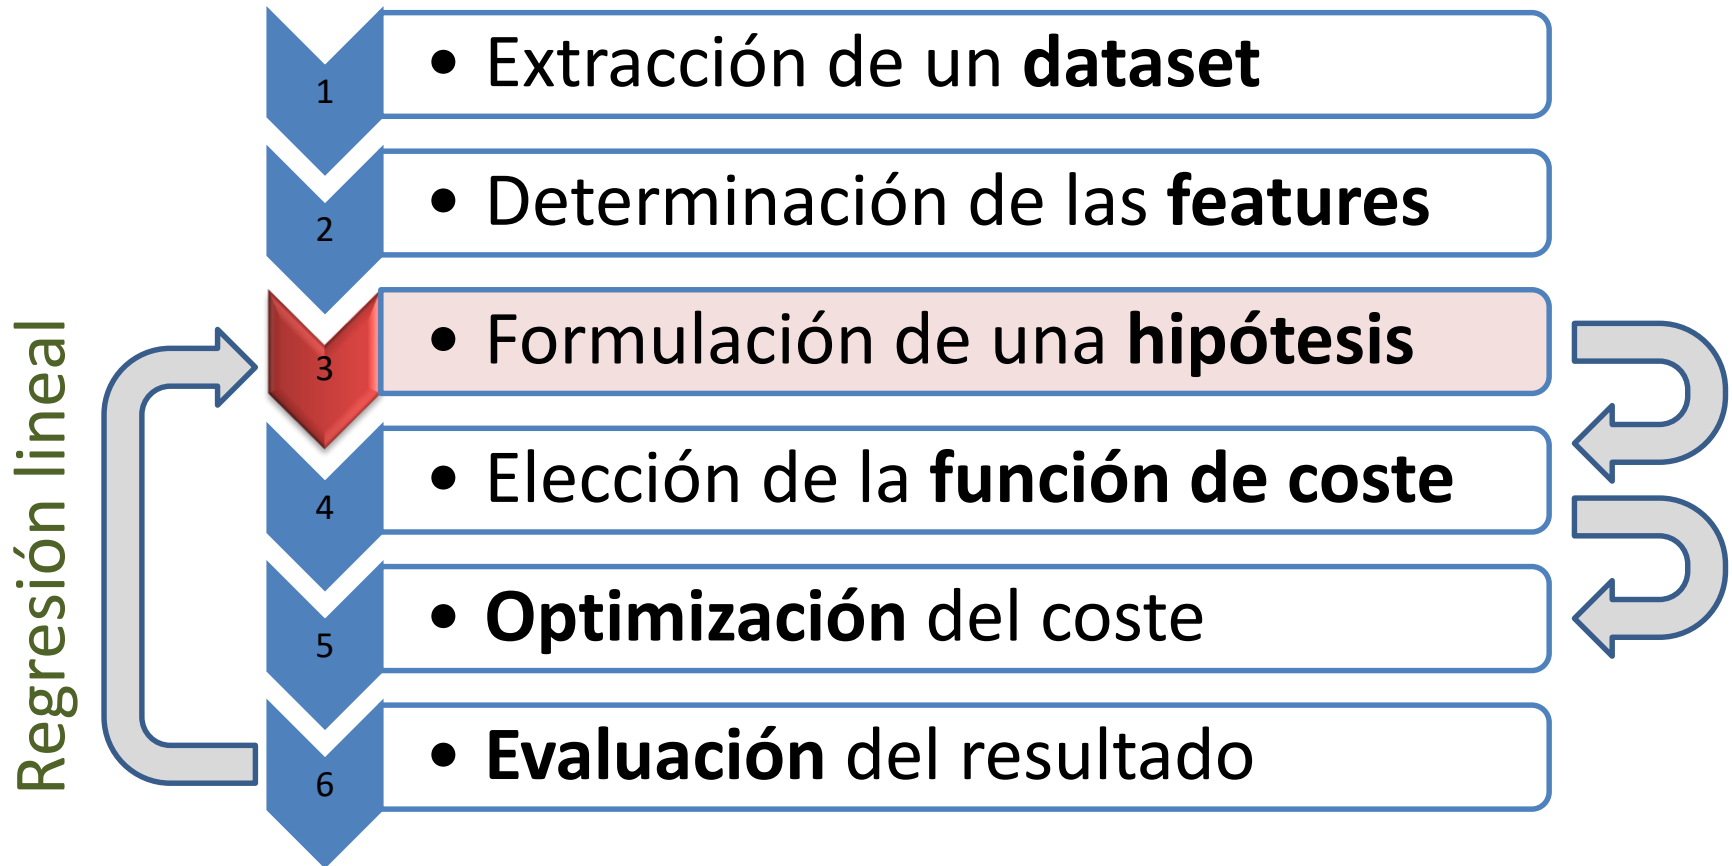
## 5. Optimización del coste



# Regresión univariable

- Muestreo
  - Hold-out
  - Cros-validación
- **Hipótesis**
  - Regresión lineal (sin *offset*)
  - **Regresión lineal**
  - Regresión polinómica
- Función de coste
  - Cuadrática
  - Regularización (regresión de arista)
- Optimización
  - Ecuación normal
  - Gradiente descendente
- Evaluación
  - Bootstrap


# Pasos del *machine learning*





# Regresión lineal

## 3. Formulación de hipótesis



La posición de la recta depende de los parámetros  $w_0$  y  $w_1$

$$\text{Hipótesis } h_w(x) = w_0 + w_1x$$

# Regresión lineal

## 3. Formulación de hipótesis

$$h_w(x) = w_0 + w_1 x$$


$$x = \begin{bmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(n)} \end{bmatrix} \Rightarrow \mathbb{X} = \begin{bmatrix} 1 & x^{(1)} \\ 1 & x^{(2)} \\ \vdots & \vdots \\ 1 & x^{(n)} \end{bmatrix}$$

$$w = [w_0 \quad w_1]; \quad w^T = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}$$

$$h_w(x) = \mathbb{X}w^T$$

# Regresión lineal

## 4. Elección de la función de coste




Error  
cuadrático  
medio

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

# Regresión lineal

## 4. Elección de la función de coste



Error  
cuadrático  
medio

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

# Regresión lineal

## 4. Elección de la función de coste

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$h_w(x) = w_0 + w_1 x$$

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

# Regresión lineal

## 4. Elección de la función de coste

$$\mathbb{X}w^T - y = \begin{bmatrix} w_0 + w_1 x^{(1)} \\ w_0 + w_1 x^{(2)} \\ \vdots \\ w_0 + w_1 x^{(n)} \end{bmatrix} - \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix} = \begin{bmatrix} w_0 + w_1 x^{(1)} - y^{(1)} \\ w_0 + w_1 x^{(2)} - y^{(2)} \\ \vdots \\ w_0 + w_1 x^{(n)} - y^{(n)} \end{bmatrix}$$

$$(\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) = \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)})^2$$

$$J(h_w(x), y) = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y)$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$w^* = \arg \min_w J(h_w(x), y)$$

$$w^* = \arg \min_w \left[ \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y) \right]$$

$$\frac{\partial}{\partial w_j} J(h_w(x), y) = 0, \forall j$$

$\nabla$ : operador nabla

$\nabla J$ : gradiente

$$\nabla J(h_w(x), y) \equiv \begin{bmatrix} \frac{\partial J}{\partial w_0} \\ \frac{\partial J}{\partial w_1} \end{bmatrix} = 0$$

# Regresión lineal

## 5. Optimización mediante Normal Equation



$$\nabla J \equiv \begin{bmatrix} \frac{\partial J}{\partial w_0} \\ \frac{\partial J}{\partial w_1} \end{bmatrix}$$

Jacobiano

$$H \equiv \nabla^2 J \equiv \begin{bmatrix} \frac{\partial^2 J}{\partial w_0^2} & \frac{\partial^2 J}{\partial w_0 \partial w_1} \\ \frac{\partial^2 J}{\partial w_1 \partial w_0} & \frac{\partial^2 J}{\partial w_1^2} \end{bmatrix}$$

Hessiano



# Regresión lineal

## 5. Optimización mediante Normal Equation

$$J = \frac{1}{n} (\mathbb{X}w^T - y)^T (\mathbb{X}w^T - y)$$

$$J = \frac{1}{n} [(\mathbb{X}w^T)^T - y^T] (\mathbb{X}w^T - y)$$

$$J = \frac{1}{n} (w\mathbb{X}^T - y^T) (\mathbb{X}w^T - y)$$

$$J = \frac{1}{n} (w\mathbb{X}^T \mathbb{X}w^T - w\mathbb{X}^T y - y^T \mathbb{X}w^T + y^T y)$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\begin{matrix} & \begin{matrix} (1+2) & (2+n) & (n+1) \end{matrix} \\ (1 \times 1) & w \mathbb{X}^T y = (w \mathbb{X}^T y)^T = y^T (w \mathbb{X}^T)^T = y^T \mathbb{X} w^T & \begin{matrix} (1+n) & (n+2) & (2+1) \end{matrix} \\ & & (1 \times 1) \end{matrix}$$

$$J = \frac{1}{n} (w \mathbb{X}^T \mathbb{X} w^T - 2w \mathbb{X}^T y + y^T y)$$

$$\mathbb{X} = \begin{bmatrix} 1 & x^{(1)} \\ 1 & x^{(2)} \\ \vdots & \vdots \\ 1 & x^{(n)} \end{bmatrix}; y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

$$w = [w_0 \quad w_1]; \quad w^T = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\mathbb{X}^T \mathbb{X} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x^{(1)} & x^{(2)} & \dots & x^{(n)} \end{bmatrix} \begin{bmatrix} 1 & x^{(1)} \\ 1 & x^{(2)} \\ \vdots & \vdots \\ 1 & x^{(n)} \end{bmatrix}$$

$$\mathbb{X}^T \mathbb{X} = \begin{bmatrix} 1^2 + 1^2 + \dots + 1^2 & x^{(1)} + x^{(2)} + \dots + x^{(n)} \\ x^{(1)} + x^{(2)} + \dots + x^{(n)} & x^{(1)^2} + x^{(2)^2} + \dots + x^{(n)^2} \end{bmatrix}$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\mathbb{X}^T \mathbb{X} = \begin{bmatrix} \sum_{i=1}^n 1^2 & \sum_{i=1}^n x^{(i)} \\ \sum_{i=1}^n x^{(i)} & \sum_{i=1}^n x^{(i)2} \end{bmatrix}$$

$$\mathbb{X}^T \mathbb{X} \mathbf{w}^T = \begin{bmatrix} \sum_{i=1}^n 1^2 & \sum_{i=1}^n x^{(i)} \\ \sum_{i=1}^n x^{(i)} & \sum_{i=1}^n x^{(i)2} \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\mathbb{X}^T \mathbb{X} \mathbf{w}^T = \begin{bmatrix} w_0 \sum_{i=1}^n 1^2 + w_1 \sum_{i=1}^n x^{(i)} \\ w_0 \sum_{i=1}^n x^{(i)} + w_1 \sum_{i=1}^n x^{(i)^2} \end{bmatrix}$$

$$\mathbf{w} \mathbb{X}^T \mathbb{X} \mathbf{w}^T = [w_0 \quad w_1] \mathbb{X}^T \mathbb{X} \mathbf{w}^T = w_0 w_0 \sum_{i=1}^n 1^2 + w_0 w_1 \sum_{i=1}^n x^{(i)} + w_1 w_0 \sum_{i=1}^n x^{(i)} + w_1 w_1 \sum_{i=1}^n x^{(i)^2}$$



# Regresión lineal

## 5. Optimización mediante Normal Equation

$$wX^T X w^T = w_0^2 \sum_{i=1}^n 1^2 + 2w_0 w_1 \sum_{i=1}^n x^{(i)} + w_1^2 \sum_{i=1}^n x^{(i)2}$$

$$wX^T y = [w_0 \quad w_1] \begin{bmatrix} 1 & 1 & \dots & 1 \\ x^{(1)} & x^{(2)} & \dots & x^{(n)} \end{bmatrix} y$$

$$wX^T y = [w_0 + w_1 x^{(1)} \quad w_0 + w_1 x^{(2)} \quad \dots \quad w_0 + w_1 x^{(n)}] y$$

$$wX^T y = (w_0 + w_1 x^{(1)})y^{(1)} + (w_0 + w_1 x^{(1)})y^{(2)} + \dots + (w_0 + w_1 x^{(1)})y^{(n)}$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$wX^T y = \sum_{i=1}^n (w_0 + w_1 x^{(i)}) y^{(i)}$$

$$y^T y = \sum_{i=1}^n y^{(i)2}$$

$$nJ = w_0^2 \sum_{i=1}^n 1^2 + 2w_0w_1 \sum_{i=1}^n x^{(i)} + w_1^2 \sum_{i=1}^n x^{(i)2} -$$
$$2 \sum_{i=1}^n (w_0 + w_1 x^{(i)}) y^{(i)} + \sum_{i=1}^n y^{(i)2}$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\frac{\partial J}{\partial \mathbf{w}} = \begin{bmatrix} \frac{\partial J}{\partial w_0} \\ \frac{\partial J}{\partial w_1} \end{bmatrix}$$

$$n \left( \frac{\partial J}{\partial \mathbf{w}} \right) = \begin{bmatrix} 2w_0 \sum_{i=1}^n 1^2 + 2w_1 \sum_{i=1}^n x^{(i)} - 2 \sum_{i=1}^n y^{(i)} \\ 2w_1 \sum_{i=1}^n x^{(i)2} + 2w_0 \sum_{i=1}^n x^{(i)} - 2 \sum_{i=1}^n x^{(i)} y^{(i)} \end{bmatrix}$$



# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\frac{\partial J}{\partial w_0} = \frac{2}{n} \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)})$$

$$\frac{\partial J}{\partial w_1} = \frac{2w_1}{n} \sum_{i=1}^n x^{(i)2} + \frac{2w_0}{n} \sum_{i=1}^n x^{(i)} - \frac{2}{n} \sum_{i=1}^n x^{(i)} y^{(i)}$$

$$\frac{\partial J}{\partial w_1} = \frac{2}{n} \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)}) x^{(i)}$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\left(\frac{\partial J}{\partial \mathbf{w}}\right) = \begin{bmatrix} \frac{\partial J}{\partial w_0} \\ \frac{\partial J}{\partial w_1} \end{bmatrix}$$

$$n \left(\frac{\partial J}{\partial \mathbf{w}}\right) = 2 \begin{bmatrix} w_0 \sum_{i=1}^n 1^2 + w_1 \sum_{i=1}^n x^{(i)} \\ w_1 \sum_{i=1}^n x^{(i)2} + w_0 \sum_{i=1}^n x^{(i)} \end{bmatrix} - 2 \begin{bmatrix} \sum_{i=1}^n y^{(i)} \\ \sum_{i=1}^n x^{(i)} y^{(i)} \end{bmatrix}$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\mathbb{X}^T \mathbf{y} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x^{(1)} & x^{(2)} & \dots & x^{(n)} \end{bmatrix} \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n y^{(i)} \\ \sum_{i=1}^n x^{(i)} y^{(i)} \end{bmatrix}$$

$$n \left( \frac{\partial J}{\partial \mathbf{w}} \right) = 2 \mathbb{X}^T \mathbb{X} \mathbf{w}^T - 2 \mathbb{X}^T \mathbf{y}$$

$$\nabla J = \frac{\partial J}{\partial \mathbf{w}} = \frac{2}{n} (\mathbb{X}^T \mathbb{X} \mathbf{w}^T - \mathbb{X}^T \mathbf{y}) = 0$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\nabla J = \frac{2}{n} (\mathbb{X}^T \mathbb{X} w^T - \mathbb{X}^T y)^T$$

$$\nabla J = \frac{2}{n} [(\mathbb{X}^T \mathbb{X} w^T)^T - (\mathbb{X}^T y)^T]$$

$$\nabla J = \frac{2}{n} [w(\mathbb{X}^T \mathbb{X})^T - y^T \mathbb{X}]$$

$$\nabla J = \frac{2}{n} (w \mathbb{X}^T \mathbb{X} - y^T \mathbb{X}) = 0$$

$$w^* \mathbb{X}^T \mathbb{X} = y^T \mathbb{X}$$

$$w^* = y^T \mathbb{X} (\mathbb{X}^T \mathbb{X})^{-1}$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$H \equiv \nabla^2 J = \begin{bmatrix} \frac{\partial^2 J}{\partial w_0^2} & \frac{\partial^2 J}{\partial w_0 \partial w_1} \\ \frac{\partial^2 J}{\partial w_1 \partial w_0} & \frac{\partial^2 J}{\partial w_1^2} \end{bmatrix}$$

Condición de convexidad:

El Hessiano es una matriz semidefinida positiva

$$z = \begin{bmatrix} z_0 \\ z_1 \end{bmatrix} \in \mathbb{R}^2 \quad z^T H z \geq 0$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\frac{\partial J}{\partial w_0} = \frac{2}{n} \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)})$$

$$\frac{\partial^2 J}{\partial w_0^2} = \frac{2}{n} \sum_{i=1}^n 1 = 2$$

$$\frac{\partial^2 J}{\partial w_1 \partial w_0} = \frac{2}{n} \sum_{i=1}^n x^{(i)}$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$\frac{\partial J}{\partial w_1} = \frac{2}{n} \sum_{i=1}^n (w_0 + w_1 x^{(i)} - y^{(i)}) x^{(i)}$$

$$\frac{\partial^2 J}{\partial w_0 \partial w_1} = \frac{2}{n} \sum_{i=1}^n x^{(i)}$$

$$\frac{\partial^2 J}{\partial w_1^2} = \frac{2}{n} \sum_{i=1}^n x^{(i)2}$$



# Regresión lineal

## 5. Optimización mediante Normal Equation

$$H \equiv \nabla^2 J = \frac{2}{n} \begin{bmatrix} n & \sum_{i=1}^n x^{(i)} \\ \sum_{i=1}^n x^{(i)} & \sum_{i=1}^n x^{(i)2} \end{bmatrix} = \frac{2}{n} \mathbb{X}^T \mathbb{X}$$

Condición de convexidad:

El Hessiano es una matriz semidefinida positiva

$$z = \begin{bmatrix} z_0 \\ z_1 \end{bmatrix} \in \mathbb{R}^2$$

$$z^T H z \geq 0$$



# Regresión lineal

## 5. Optimización mediante Normal Equation

$$z^T H z = [z_0 \quad z_1] \frac{2}{n} \begin{bmatrix} n & \sum_{i=1}^n x^{(i)} \\ \sum_{i=1}^n x^{(i)} & \sum_{i=1}^n x^{(i)2} \end{bmatrix} \begin{bmatrix} z_0 \\ z_1 \end{bmatrix}$$

$$z^T H z = \frac{2}{n} \begin{bmatrix} z_0 n + z_1 \sum_{i=1}^n x^{(i)} & z_0 \sum_{i=1}^n x^{(i)} + z_1 \sum_{i=1}^n x^{(i)2} \end{bmatrix} \begin{bmatrix} z_0 \\ z_1 \end{bmatrix}$$

$$z^T H z = \frac{2}{n} \left( z_0^2 n + z_0 z_1 \sum_{i=1}^n x^{(i)} + z_1 z_0 \sum_{i=1}^n x^{(i)} + z_1^2 \sum_{i=1}^n x^{(i)2} \right)$$

# Regresión lineal

## 5. Optimización mediante Normal Equation

$$z^T H z = \frac{2}{n} \left( z_0^2 \sum_{i=1}^n 1 + 2z_0 z_1 \sum_{i=1}^n x^{(i)} + z_1^2 \sum_{i=1}^n x^{(i)2} \right)$$

$$z^T H z = \frac{2}{n} \left( \sum_{i=1}^n z_0^2 + \sum_{i=1}^n 2z_0 z_1 x^{(i)} + \sum_{i=1}^n z_1^2 x^{(i)2} \right)$$

$$z^T H z = \frac{2}{n} \sum_{i=1}^n \left( z_0^2 + 2z_0 z_1 x^{(i)} + z_1^2 x^{(i)2} \right)$$

# Regresión lineal

## 5. Optimización mediante Normal Equation


$$z^T H z = \frac{2}{n} \sum_{i=1}^n \left( z_0 + z_1 x^{(i)} \right)^2$$

$$\left( z_0 + z_1 x^{(i)} \right)^2 \geq 0, \forall z, x^{(i)} \in \mathbb{R}^2$$

$$z^T H z \geq 0$$

# Regresión lineal


## 5. Optimización mediante Normal Equation



$$w^* = y^T X (X^T X)^{-1} = [1.75 \quad 0.17]$$

# Regresión lineal

## 5. Optimización mediante Gradient Descent




$$w_0^{(t+1)} \leftarrow w_0^{(t)} - \alpha \frac{\partial J(w)}{\partial w_0}$$

$$w_1^{(t+1)} \leftarrow w_1^{(t)} - \alpha \frac{\partial J(w)}{\partial w_1}$$

# Regresión lineal

## 5. Optimización mediante Gradient Descent

SGD



BGD

