

Contenido

1. Introducción
2. Regresión
 - a) Regresión univariable
 - b) **Regresión multivariable**
3. Clasificación
 - a) Regresión logística
 - b) Máquinas de vectores soporte (SVM)
 - Forma dual de la optimización (regresión y SVM)
 - c) Funciones Kernel
 - d) Clasificación multiclase
4. Segmentación
5. Reducción de dimensionalidad
6. Deep learning (introducción)

Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- Normalización de variables
- Descomposición en Valores Singulares
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Regresión multivariable


Ejemplo en el sector eléctrico

- En otra zona en la que opera la empresa los datos disponibles de los clientes para hacer la predicción de su consumo de energía son los siguientes:
 1. Ingresos anuales (€)
 2. Número de habitantes en la vivienda (promedio anual de personas)
 3. Potencia contratada (kW)
 4. Tipo de vivienda (piso, adosado, casa)
 5. Superficie de la vivienda (m²)
 6. Horas de ocupación en invierno (horas/día)
 7. Horas de ocupación en verano (horas/día)
 8. Edad (años)
 9. Estado civil (soltero, casado, separado, viudo)
 10. Nivel de estudios alcanzado (sin estudios, primaria, secundaria, bachiller, grado, máster, doctor)

Regresión multivariable

2. Determinación de *features*

Muestra \mathcal{M}
(dataset)



n elementos

i -ésimo elemento

Caracterizado por d features (rasgos):

- $x^{(i)}$: vector fila con d features

Valor del objetivo (target) :

- $y^{(i)}$: consumo anual de electricidad

$$(n \times d) \quad X = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{bmatrix} \quad (n \times 1) \quad y^{(i)} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$


2. Determinación de *features*

[illegible]


Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- Normalización de variables
- Descomposición en Valores Singulares
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation


Representación multivariable




Representación multivariable




Representación multivariable



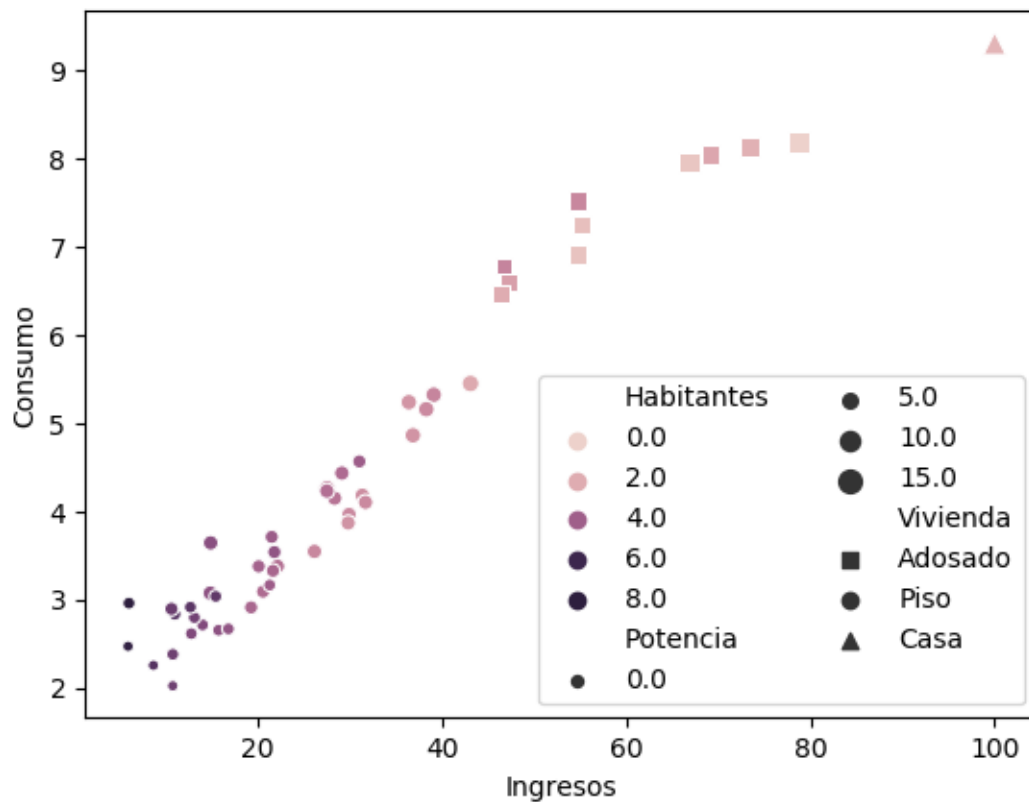
Representación multivariable



Representación multivariable



Representación multivariable



Regresión multivariable

- Representación gráfica multivariable
- **Codificación 1-hot**
- Normalización de variables
- Descomposición en Valores Singulares
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Regresión multivariable

2. Determinación de *features*


- Estructurados
 - Numéricos
 - Continuos
 - Discretos
 - Categóricos
 - Ordinales
 - Nominales
- Series temporales
- Imagen
- Vídeo
- Audio
- Texto

Regresión multivariable

2. Determinación de *features*

Range of potential AI value impact by data type

% of total value potential



SOURCE: McKinsey Global Institute analysis

Aplicar ML a distintos sectores productivos supone una mejora económica (reducción de costes, etc.) con un determinado valor total (€).

La gráfica representa el porcentaje que en dicha mejora global juega cada tipo de datos.

Regresión multivariable

2. Determinación de *features*

- Numérica
 - Continua
 - Ingresos; promedio de habitantes; superficie; horas invierno; horas verano; edad
 - Discreta
 - Potencia
- Categórica
 - Ordinal (con orden; tiene sentido la media)
 - Estudios
 - Nominal (sin orden; no tiene sentido la media)
 - Tipo de vivienda; estado civil
 - 1-hot encoding

1-hot encoding

Tipo de vivienda	Piso	Adosado	Casa
Piso	1	0	0
Adosado	0	1	0
Casa	0	0	1

Estado civil	Soltero	Casado	Separado	Viudo
Soltero	1	0	0	0
Casado	0	1	0	0
Separado	0	0	1	0
Viudo	0	0	0	1

1-hot encoding

[illegible]

Regresión multivariable

3. Formulación de hipótesis

$$h_w(x) = w_1x_1 + w_2x_2 + \cdots + w_dx_d$$

$$X = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \cdots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{bmatrix} \quad w = [w_1 \quad w_2 \quad \cdots \quad w_d]$$

Regresión multivariable

4. Elección de la función de coste

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$Xw^T - y = \begin{bmatrix} w_1 x_1^{(1)} + w_2 x_2^{(1)} + \cdots + w_d x_d^{(1)} - y^{(1)} \\ w_1 x_1^{(2)} + w_2 x_2^{(2)} + \cdots + w_d x_d^{(2)} - y^{(2)} \\ \vdots \\ w_1 x_1^{(n)} + w_2 x_2^{(n)} + \cdots + w_d x_d^{(n)} - y^{(n)} \end{bmatrix}$$

Regresión multivariable

4. Elección de la función de coste

$$(X - y)^T (Xw^T - y) = \sum_{i=1}^n \left(w_1 x_1^{(i)} + w_2 x_2^{(i)} + \dots + w_d x_d^{(i)} - y^{(1)} \right)^2$$

$$J(h_w(x), y) = \frac{1}{n} (X - y)^T (Xw^T - y)$$

$$J(h_w(x), y) = \frac{1}{n} (X - y)^T (Xw^T - y) + \lambda \|w\|_2^2$$

Regresión multivariable

5. Optimización mediante Normal Equation

$$\nabla J(h_w(x), y) = 0$$

$$\nabla \left[\frac{1}{n} (X - y)^T (Xw^T - y) + \lambda \|w\|_2^2 \right] = 0$$

$$\nabla J(h_w(x), y) = \frac{2}{n} (wX^T X - y^T X) + 2\lambda w = 0$$

$$w^* = y^T X (X^T X + n\lambda I_d)^{-1}$$

Regresión multivariable

5. Optimización mediante Gradient Descent

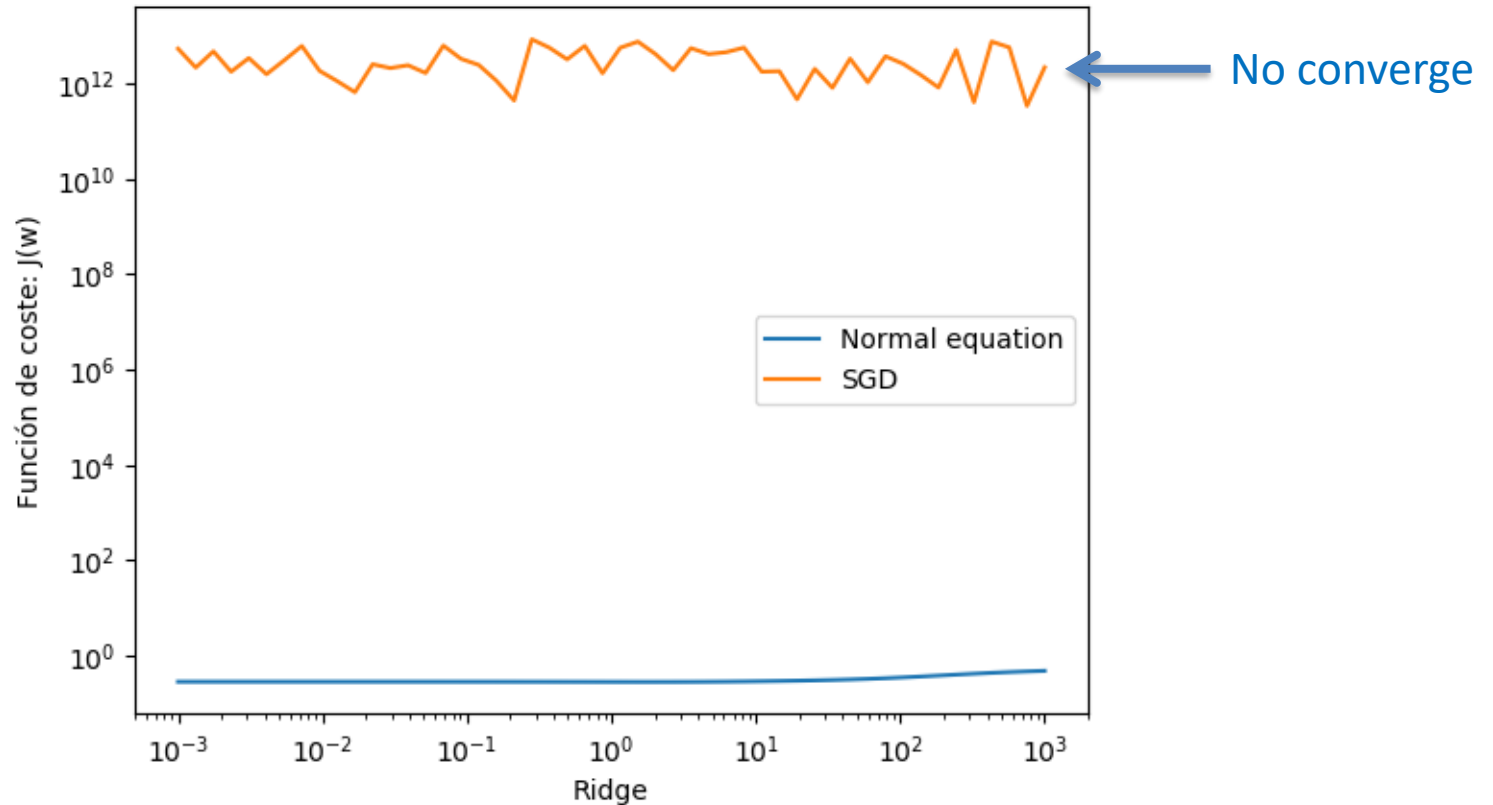
$$\begin{bmatrix} w_1^{(t+1)} \\ \vdots \\ w_d^{(t+1)} \end{bmatrix} \leftarrow \begin{bmatrix} w_1^{(t)} \\ \vdots \\ w_d^{(t)} \end{bmatrix} - \alpha \begin{bmatrix} \frac{\partial J(h_w(x), y)}{\partial w_1} \\ \vdots \\ \frac{\partial J(h_w(x), y)}{\partial w_d} \end{bmatrix}$$

$$w^{(t+1)T} \leftarrow w^{(t)T} - \alpha \nabla J$$

$$w^{(t+1)T} \leftarrow w^{(t)T} - \alpha \left(\frac{2}{n} (wX^T X - y^T X) + 2\lambda w \right)$$

Regresión multivariable


6. Evaluación del resultado





Regresión multivariable

- Representación gráfica multivariable
- Codificación 1-hot
- **Normalización de variables**
- Descomposición en Valores Singulares
 - Matrices de covarianza y Gramm
 - Autovalores y autovectores
 - Definición de la SVD
 - Obtención de la SVD
 - Aplicación a la solución de la Normal Equation

Normalización de variables



Normalización de variables



Coste escala logarítmica

$$\lambda = 0$$

Normalización de variables

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (h_w(x^{(i)}) - y^{(i)})^2$$

$$J(h_w(x), y) = \frac{1}{n} \sum_{i=1}^n (w_1 x_1^{(i)} + w_2 x_2^{(i)} - y^{(i)})^2$$

Orden de magnitud: $O_m(\cdot)$

$$O_m(w_1) = \frac{O_m(y)}{O_m(x_1)}; O_m(w_2) = \frac{O_m(y)}{O_m(x_2)}; O_m(J) = (O_m(y))^2$$

10^3 10^0 10^1 10^2 10^6 10^3

Normalización de variables

$$\frac{\partial J}{\partial w_1} = \frac{1}{n} \sum_{i=1}^n \frac{\partial}{\partial w_1} \left(w_1 x_1^{(i)} + w_2 x_2^{(i)} - y^{(i)} \right)^2$$

$$\frac{\partial J}{\partial w_1} = \frac{2}{n} \sum_{i=1}^n x_1^{(i)} \left(w_1 x_1^{(i)} + w_2 x_2^{(i)} - y^{(i)} \right)$$

$$\frac{\partial J}{\partial w_2} = \frac{2}{n} \sum_{i=1}^n x_2^{(i)} \left(w_1 x_1^{(i)} + w_2 x_2^{(i)} - y^{(i)} \right)$$

Normalización de variables

$$\begin{bmatrix} w_1^{(t+1)} \\ w_2^{(t+1)} \end{bmatrix} \leftarrow \begin{bmatrix} w_1^{(t)} \\ w_2^{(t)} \end{bmatrix} - \alpha \begin{bmatrix} \frac{\partial J(h_w(x), y)}{\partial w_1} \\ \frac{\partial J(h_w(x), y)}{\partial w_2} \end{bmatrix}$$

$$\begin{bmatrix} \Delta w_1^{(t)} \\ \Delta w_2^{(t)} \end{bmatrix} = -\alpha \begin{bmatrix} \frac{\partial J(h_w(x), y)}{\partial w_1} \\ \frac{\partial J(h_w(x), y)}{\partial w_2} \end{bmatrix}$$

Normalización de variables

$$O_m \left(\Delta w_1^{(t)} \right) = O_m(\alpha) O_m \left(\frac{\partial J}{\partial w_1} \right) = O_m(\alpha) O_m(x_1) O_m(y)$$

10^2 10^{-1} 10^3 10^{-1} 10^0 10^3

$$O_m \left(\frac{\Delta w_1^{(t)}}{w_1} \right) = \frac{O_m(\alpha) O_m(x_1) O_m(y)}{\frac{O_m(y)}{O_m(x_1)}} = O_m(\alpha) O_m(x_1)^2$$

10^2 10^3 10^{-1} $(10^0)^2$

Normalización de variables

$$O_m \left(\Delta w_2^{(t)} \right) = O_m(\alpha) O_m \left(\frac{\partial J}{\partial w_2} \right) = O_m(\alpha) O_m(x_2) O_m(y)$$

10^4 10^{-1} 10^5 10^{-1} 10^2 10^3

$$O_m \left(\frac{\Delta w_2^{(t)}}{w_2} \right) = \frac{O_m(\alpha) O_m(x_2) O_m(y)}{\frac{O_m(y)}{O_m(x_2)}} = O_m(\alpha) O_m(x_2)^2$$

10^4 10^{-1} $(10^2)^2$ 10^1


Normalización de variables

$$\frac{10^{-1} O_m \left(\frac{\Delta w_1^{(t)}}{w_1} \right)}{10^3 O_m \left(\frac{\Delta w_2^{(t)}}{w_2} \right)} = \frac{O_m(\alpha) O_m(x_1)^2}{O_m(\alpha) O_m(x_2)^2}$$


$$\frac{O_m \left(\frac{\Delta w_1^{(t)}}{w_1} \right)}{O_m \left(\frac{\Delta w_2^{(t)}}{w_2} \right)} = \frac{(10^0)^2}{(10^2)^2} = 10^{-4}$$

Normalización de variables

Coste escala logarítmica
 $\lambda = 100$




x




$$\frac{x - \mu}{\sigma}$$

Normalización de variables



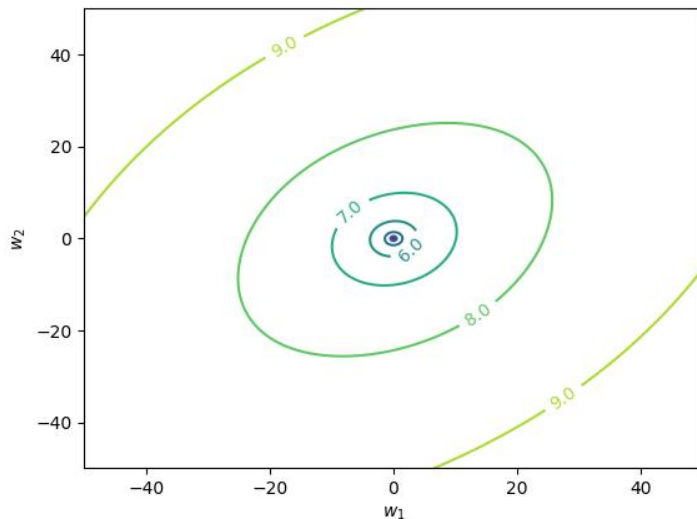
$\lambda = 100$

x




$x - \mu$

Coste escala logarítmica




x
 σ




$\frac{x - \mu}{\sigma}$

Normalización de variables




$$\lambda = 0$$

x




$x - \mu$

Coste escala logarítmica

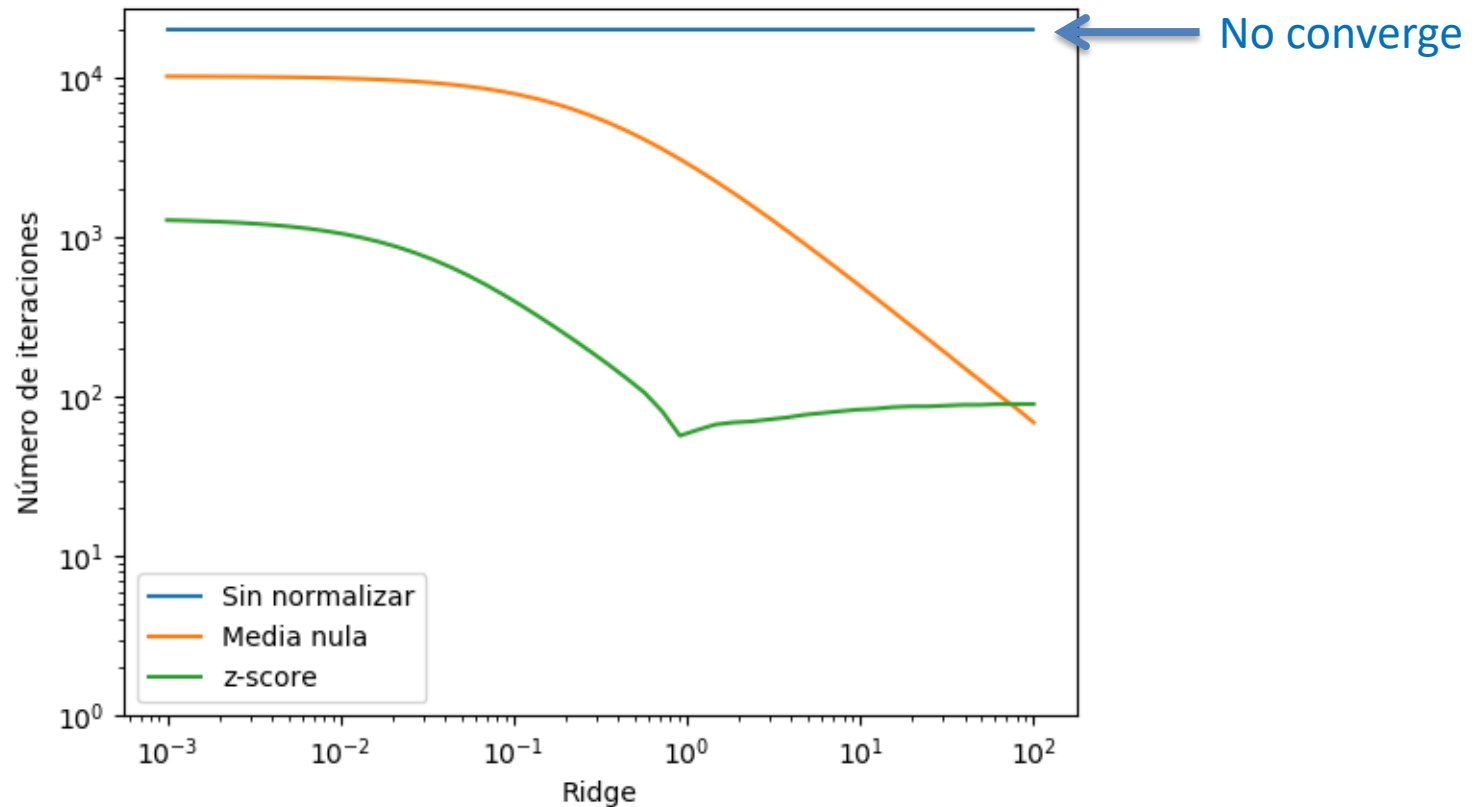


x
 σ

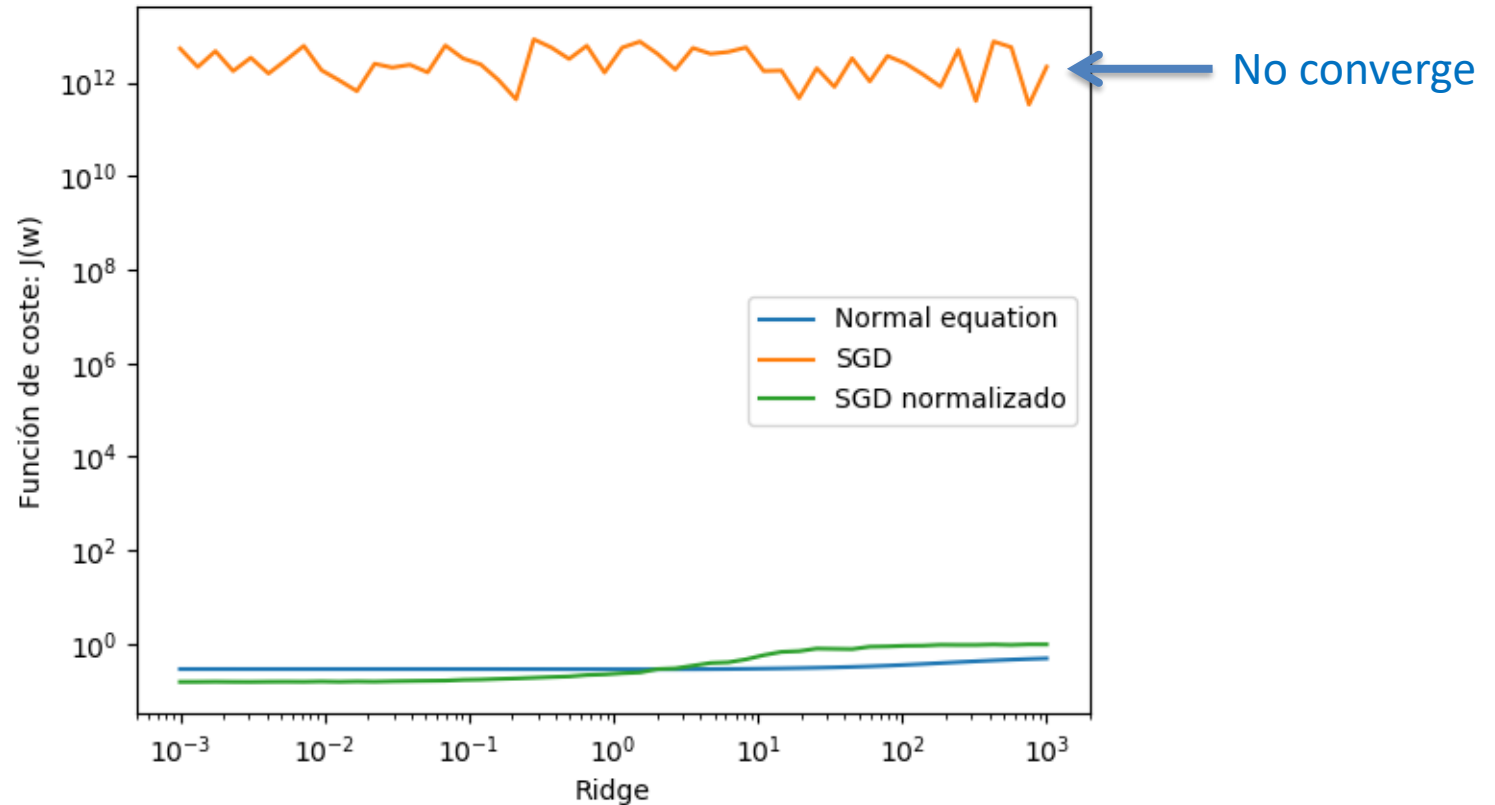


$\frac{x - \mu}{\sigma}$

Normalización de variables



Normalización de variables



Normalización de variables

z-score

Media nula

Varianza unitaria

$$x' = \frac{x - \mu_x}{\sigma_x}$$

Media nula

$$x' = \frac{x - \mu_x}{\max(x) - \min(x)}$$

Reescalado
min-max

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Reescalado
por rango

$$x' = \frac{x - \mu_x}{\text{rango}(x)}$$